

LLM, модели и токены

С чем ты работаешь: что такое модель, какую выбрать и за что списываются токены

модуль 1 · постановка задачи

opencode

💡 Что такое LLM

LLM (large language model, большая языковая модель) — ИИ, обученный на огромном объеме текстов. Она не хранит факты и не «понимает» смысл, как человек, а предсказывает самое вероятное продолжение текста — слово за словом. Так и собирается ответ.

01 Поэтому помни, что LLM

🌀 Додумывает за тебя

Где данных нет — подставит правдоподобное. Уверенно, но иногда неверно. Это называют галлюцинацией.

🗑️ Не знает твоего контекста

Внутренних данных твоей компании, свежих событий и деталей задачи в обучении не было — не дашь в запросе, ей неоткуда взять.

🗨️ Уверенный тон ≠ правота

Гладкость ответа — про устройство модели, а не про его верность. Проверка остаётся за тобой.

02 Классы моделей — бери под задачу, а не «самую мощную»

Текстовая (универсальная)

Письма, тексты, разбор, переписка. Базовый рабочий выбор для большинства задач.

В opencode: `claude-sonnet-4-6`, `gpt-4.1`, `deepseek-chat`, `qwen-max`, `glm-4.6`.

Рассуждающая

Сложная логика, многошаговые задачи, аккуратные расчёты. Думает дольше — для простого избыточна.

В opencode: `deepseek-reasoner`, `kimi-k2-thinking` (ищи пометки `reasoner` / `thinking` в названии).

Мультимодальная

Работает не только с текстом. Бывает двух видов: понимает картинки/скриншоты/файлы и генерирует изображения.

В opencode: понимает картинки — `gpt-4o`, `claude-sonnet-4-6`; генерирует — `gpt-image-1.5`.

Кодовая

Заточена под программирование и работу с кодом.

В opencode: `qwen3-coder`, `gpt-5.2-codex`, `kimi-k2.7-code` (ищи пометки `coder` / `codex` / `code`).

03 Где выбирать и корпоративный контур безопасности

opencode — десятки моделей в одном месте

Модели сгруппированы по провайдерам (Anthropic, OpenAI, DeepSeek, Alibaba/qwen, Moonshot/kimi, z.ai/glm и др.). У каждой видно лимит контекста и цену за токены. Меняй модель под задачу: не уверен — начни с текстовой, переключись на рассуждающую, если не хватает глубины. «Лёгкие» версии (`mini` · `flash` · `turbo` · `nano` · `air`) дешевле и быстрее флагманов.

Контур безопасности

Коммерческие и внутренние данные компании — только через корпоративный контур (opencode с рабочим доступом). Во внешние сервисы — лишь то, что и так публично.

04 Токены — за что списывается и как тратить меньше

Токены = кусочки слов (≈ ¾ слова на токен)

Считаются и ввод (запрос + весь контекст диалога), и вывод (ответ модели). Чем длиннее диалог и чем больше приложенных материалов — тем дороже каждый следующий ответ. Один точный запрос дешевле и лучше, чем десять уточняющих.

Не благодари модель зря

Не веди пустую переписку — каждое сообщение стоит токенов.