

Контроль агента

Человек в контуре: доверие настраивается по риску действия, а не на каждом шаге

Модуль 4 · Работа с агентом

главное правило

01 Обратимое vs необратимое

главный вопрос: можно ли откатить?

✅ Обратимое — доверяй

- читать, искать, собирать
- делать черновик
- сводить и анализировать

🔴 Необратимое — точка контроля

- отправить письмо / разослать пользователям стриминга «Волна»
- изменить, закрыть, удалить
- запостить, выдать доступ, оплатить

02 Глубина контроля по риску

классификатор из Модуля 2

🟢 Читать · собирать · черновик	обратимо. Доверяй, не тормози
🟡 Мелкое действие	пусть делает, но покажи результат
🔴 Необратимое / заметное	точка контроля: покажи черновик, жди «ок»
⬛ Опасное и необратимое	сам не делает — или только под твоим присмотром

03 Два правила безопасной работы с ИИ

общие правила из практикума

🔑 Минимум прав

Дай только нужный доступ. По умолчанию — только чтение. Нет прав на отправку → не отправит даже по ошибке.

🛡️ Граница данных

Внутреннее — через корпоративный контур. ПДн, ключи, секреты — минимизируй. Сомнение → куратор курса в учебном кабинете AVE Analytica.

🧩 Главное правило

Обратимое — доверяй, необратимое — точка контроля. Минимум прав убирает опасность, точки контроля ловят остальное.